

RNPs aplicadas a reconocimiento de patrones en registros electromiográficos de insectos.

Héctor Salas (hecsalms@gmail.com)
G. Sebastián Pedersen (sebasped@gmail.com)



Mar 03 de Diciembre de 2019

Resumen

Se aplican redes neuronales profundas para un problema de clasificación de series temporales provenientes de mediciones electromiográficas de vinchucas.

Una serie temporal típica

Corresponde al insecto en reposo, insertando el pico, comiendo.



RNP series temp.

HS, SP

El problema

Las RNPs probadas

Continuaciones futuras

Preproceso de las series por BEADS¹



RNP series temp.

HS, SP

El problema

Las RNPs probadas

Continuaciones futuras



¹<http://www.laurent-duval.eu/siva-beads-baseline-background-removal-filtering-sparsity.html>

El problema de clasificación

RNP series temp.

HS, SP


El problema

Las RNPs probadas

Continuaciones futuras

Automatizar el proceso de detección inicio/fin de región de interés (con picos).

Distinguir regiones sin pico de regiones con pico.



Sin pico: el insecto no está comiendo.

Con pico: el insecto está comiendo (región de interés).

Partición en ventanas para clasificar

RNP series temp.


HS, SP

El problema

Las RNPs probadas

Continuaciones futuras

Se parte la serie en ventanas, cada una clasificada Sí/No región de interés.



Luego a la primera Sí: inicio región de interés

A la primera No: fin región de interés

Redes convolucionales con estas arquitecturas:

- ▶ Input: ventanas de 6 seg. O sea serial temporal 1D de 1500 datos (250 Hz).
- ▶ Convolucional 1D de 5x60 (stride=1 o 2, padding=20)
- ▶ ReLu
- ▶ Convolucional 1D de 10x30 (stride=1, padding=10)
- ▶ Max Pooling de 4 o de 2
- ▶ ReLu
- ▶ FC de 1830 a 300 (luego tanh)
- ▶ Prueba agregando FC a 300/400
- ▶ FC de 300 a Sí/No


Accuracy de aprox. 90-92 %.

Segundas redes: algo más profundas

Una red convolucional con esta arquitectura:

- ▶ Input: ventanas de 6 seg. O sea serial temporal 1D de 1500 datos (250 Hz).
- ▶ Convolutacional 1D de 5x60 (stride=1, padding=30)
- ▶ ReLu
- ▶ Convolutacional 1D de 10x30 (stride=2, padding=20)
- ▶ Max Pooling de 2
- ▶ ReLu
- ▶ Convolutacional 1D de 20x15 (stride=2, padding=30)
- ▶ Max Pooling de 2
- ▶ ReLu
- ▶ FC de 580 a 300 (luego tanh)
- ▶ FC de 300 a 100 (luego tanh)
- ▶ FC de 100 a Sí/No

Accuracy de
aprox.
93-94 %.




Terceras redes: con ventanas de 1 seg.

Una red convolucional con esta arquitectura:

- ▶ Input: ventanas de 1 seg. O sea serial temporal 1D de 250 datos (250 Hz).
- ▶ Convolucional 1D de 5x60 (stride=1, padding=30)
- ▶ ReLu
- ▶ Convolucional 1D de 10x30 (stride=2, padding=30)
- ▶ Max Pooling de 2
- ▶ ReLu
- ▶ Convolucional 1D de 20x15 (stride=2, padding=30)
- ▶ Max Pooling de 2
- ▶ ReLu
- ▶ FC de 580 a 300 (luego tanh)
- ▶ FC de 300 a 100 (luego tanh)
- ▶ FC de 100 a Sí/No

Accuracy de
aprox. 94 %.



Terceras redes: con ventanas de 1 seg.

RNP series temp.


HS, SP

El problema

Las RNP's probadas

Continuaciones futuras

Ídem antes, ahora normalizando los datos
Accuracy de aprox. 95-96 %.




Cuarta red: con las FFTs de las ventanas de 1 seg.

Prueba rápida anoche:

- ▶ Input: FFTs de las ventanas de 1 seg.
- ▶ Convolutacional 1D de 5x60 (stride=1, padding=30)
- ▶ ReLu
- ▶ Convolutacional 1D de 10x30 (stride=2, padding=30)
- ▶ Max Pooling de 2
- ▶ ReLu
- ▶ Convolutacional 1D de 20x15 (stride=2, padding=30)
- ▶ Max Pooling de 2
- ▶ ReLu
- ▶ FC de 580 a 100 (luego tanh)
- ▶ FC de 100 a Sí/No

Accuracy de aprox. 91-92 %.



¿Cómo seguir a partir de aquí?

RNP series temp.

HS, SP

El problema

Las RNP's probadas

Continuaciones futuras

- ▶ Probar con otras arquitecturas/parámetros para las CNNs.
- ▶ Probar otras Recurrentes.
- ▶ Input con series temporal + FFTs.
- ▶ Ensamblés.
- ▶ Barrer el tamaño de la ventana más exhaustivamente.
- ▶ Barrer tamaño de batch más exhaustivamente.
- ▶ Reconocer más patrones en los registros.

¡GRACIAS!